## ANALYSE DE DONNÉES

#### 15 mars 2020

Notes de cours pour enseignement à distance

### **Chapitre 3: Support Vector Machines**

Je résume ci-dessous ce qu'il faut savoir sur le classifieur SVM et comment comprendre l'essentiel. Les slides sont dispos avec le lien http://tourneret.perso.enseeiht.fr/Classification/Slides\_AD\_20192020.pdf tandis que le polycopié est ici http://tourneret.perso.enseeiht.fr/Classification/poly2003.pdf

- 1. Comment construire un classifieur SVM linéaire?
  - Slides 79 à 83
  - Poly: lire les pages 73 à 75, c'est-à-dire la section 2.2.

Ceci conduit au problème d'optimisation en bleu sur le slide 83.

- 2. Comment résoudre le problème d'optimisation du slide 83 ?
  - Cette partie est un peu technique et nécessite de savoir comment résoudre un problème d'optimisation sous contraintes. Elle est ici pour ceux qui veulent aller plus loin, sera traitée dans certains parcours et peut être sautée (pas besoin pour l'examen).
    - Slides 84 à 86
    - Poly: lire les pages 76 à 78
- 3. Comprendre l'intérêt d'introduire des slack variables  $\xi_i$ , ce qui conduit au classifieur soft-margin SVM
  - Slide 87
  - poly: Section 2.4 p. 78

Pour aller plus loin, comprendre le principe du classifieur  $\nu$ -SVM (Section 2.5 page 79 du poly)

- 4. Comprendre l'intérêt d'utiliser un prétraitement non-linéaire dans le classifieur SVM et la notion de noyau
  - Slides: 88 à 94
  - poly: Section 2.6, pages 81-84
- 5. Pour ceux qui préfèrent regarder des vidéos
  - Support vector machines (clearly explained): https://www.youtube.com/watch?v=efR1C6CvhmE
  - SVM: https://th-cam.com/video/qCPYys3rm24/support-vector-machines-introduction.html
  - Slack variables: https://www.youtube.com/watch?v=u-qP2T6s7Jw
  - Kernels: https://th-cam.com/video/xa0i0rW68-s/support-vector-machines-kernel-methods.html

### Réseaux de neurones

- 1. Comment construire un classifieur avec un réseau de neurones ?
  - Slides 96 à 97
  - Poly: lire les pages 87 à 92, c'est-à-dire les sections 3.1 et 3.2
  - Faire l'exercice 3 de l'examen de 1995, page 132 du poly
- 2. Comprendre le principe des règles d'apprentissage

Cette partie nécessite d'avoir compris la méthode du gradient. Si ce n'est pas le cas, lire pages 66 à 69 pour une fonction discriminante linéaire de la forme  $y(n) = w^T x(n)$  (d(n)) est la sortie désirée qui dans le cas d'une seule sortie vaut 1 si le vecteur x(n) appartient à la classe  $\omega_1$  et -1 si x(n) appartient à la classe  $\omega_2$ , tandis que  $w^T x(n)$  est la sortie du réseau linéaire avec une des composantes de x(n) égale à 1 pour créer le biais et les autres composantes de x(n) égales aux variables utilisées pour la classification).

- comprendre le principe de la règle de mise à jour du poly p. 93 pour une classe et admettre que cette règle se généralise à l'algorithme du slide 98.
- 3. Pour ceux qui préfèrent regarder des vidéos, je recommande les vidéos d'Andrew Ng de Stanford
  - Introduction https://www.youtube.com/watch?v=-XSPumV6v00&list=UUIXpjlxPL5Ow8rPO\_gOHISQ&index=49&t=0s
  - Définition d'un réseau de neurones : https://www.youtube.com/watch?v=EVeqrPGfuCY
  - Classification avec les réseaux de neurones : https://www.youtube.com/watch?v=gAKQOZ5zIWg
  - Rétropropagation : voir https://www.youtube.com/watch?v=0twSSFZN9Mc et https://www.youtube.com/watch?v=x\_Eamf8MHwU avec une fonction de coût différente

# Arbres de décision

- 1. Comprendre le principe de la construction d'un arbre de décision et la manière de classifier
  - Slides 102 à 107
  - Lire extrait du livre de Duda and Hart
  - Faire exercice 2 de http://tourneret.perso.enseeiht.fr/Classification/Correction\_Classification20172018.pdf
  - Decision tree?: https://www.youtube.com/watch?v=7VeUPuFGJHk&t=369s
- 2. Comprendre l'intérêt de construire des forêts d'arbres aléatoires ("random forests")
  - Random forests: https://www.youtube.com/watch?v=J4Wdy0Wc\_xQ
  - Slides 108 à 110 qui résument la vidéo