

[Cours du 21/11/2022]

Ex

$$X_i \sim N(\mu, \sigma^2)$$

$\sigma^2$  connue

$$\theta = \mu$$

$$\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\text{Biais } E(\hat{\theta}_n) - \theta = b_n(\theta)$$

$$b_n(\theta) = \frac{1}{n} \sum_{i=1}^n E(x_i) - \mu = 0$$

$\hat{\theta}_n$  est non biaisé

Variance

$$\begin{aligned} \text{Var}(\hat{\theta}_n) &= \frac{1}{n^2} \text{Var}\left(\sum x_i\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n \frac{\text{Var} x_i}{\sigma^2} \\ &= \frac{\sigma^2}{n} \end{aligned}$$

$x_1, \dots, x_n$  ind

$$\tilde{\theta}_n = \frac{1}{n(n+1)} \sum_{i=1}^n (rx_i) \quad \leftarrow$$

$$E(\tilde{\theta}_n) = \frac{1}{n(n+1)} \sum_{i=1}^n i E(x_i)$$

$$= \frac{1}{n(n+1)} \sum_{i=1}^n i = m$$

$\tilde{\theta}_n$  est un estimateur non biaisé de  $m$

$$\text{Var}(\tilde{\theta}_n) = \frac{4}{n^2(n+1)} \sum_{i=1}^n (i^2 \sigma^2)$$

$$\sum_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{6}$$

Rappel

$$\text{donc } \text{var}(\tilde{\theta}_n) = \frac{4\sigma^2}{6} \frac{n(n+1)(2n+1)}{n^2(n+1)^2}$$

$$= \frac{2\sigma^2}{3} \frac{2n+1}{n(n+1)}$$

$$\approx \frac{4\sigma^2}{3n} \approx \frac{2}{n} \sigma^2$$

Example 2

$$X_i \sim N(m, \sigma^2)$$

met  $\sigma^2$  inconnus

$$\hat{\theta} = \begin{pmatrix} \hat{\theta}_1 = \frac{1}{n} \sum_{i=1}^n X_i = \bar{x} \\ \hat{\theta}_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{x})^2 \end{pmatrix} \quad \Theta = \begin{pmatrix} m \\ \sigma^2 \end{pmatrix}$$

$$\text{Rq} \quad \frac{1}{n} \sum (X_i - \bar{x})^2 = \frac{1}{n} \sum X_i^2 - \left( \frac{1}{n} \sum X_i \right)^2$$

Biais de  $\hat{\theta}$

$$\begin{bmatrix} E[\hat{\theta}_1] & -\theta_1 \\ E[\hat{\theta}_2] & -\theta_2 \end{bmatrix} \in \mathbb{R}^2 = \begin{bmatrix} E[\hat{\theta}_1] - m \\ E[\hat{\theta}_2] - \sigma^2 \end{bmatrix}$$

$$\text{on a vu } E[\hat{\theta}_1] = m \text{ donc } E[\hat{\theta}_1] - m = 0$$

$$\begin{aligned} E[\hat{\theta}_2] &\stackrel{?}{=} \frac{1}{n} \sum_{i=1}^n E[(X_i - m + m - \bar{x})^2] \\ &\quad (X_i - m)^2 + (m - \bar{x})^2 + 2(X_i - m)(m - \bar{x}) \\ &= \frac{1}{n} \sum_{i=1}^n \underbrace{E[(X_i - m)^2]}_{\sigma^2} + \underbrace{E[(m - \bar{x})^2]}_{\text{var } \bar{x}} - 2E[(X_i - m)(m - \bar{x})] \\ &\quad \text{var } \bar{x} = E[(\bar{x} - E[\bar{x}])^2] = \frac{\sigma^2}{n} \end{aligned}$$

?

$$- 2E[(X_i - m) \left( \frac{1}{n} \sum_{k=1}^n X_k - \frac{1}{n} \sum_{k=1}^n m \right)]$$

$$- \frac{2}{n} E \left[ \sum_{k=1}^n (X_i - m)(X_k - m) \right]$$

$$- \frac{2}{n} \sum_{k=1}^n \underbrace{E[(X_i - m)(X_k - m)]}_{\text{cov}(X_i, X_k)} = \begin{cases} -\frac{2\sigma^2}{n} & k=i \\ 0 & k \neq i \end{cases}$$

On en déduit

$$E[\hat{\theta}_2] = \sigma^2 + \frac{\sigma^2}{n} - 2\frac{\sigma^2}{n} = \boxed{\sigma^2 \left( \frac{n-1}{n} \right)}$$

Cette analyse permet de proposer un nouvel estimateur

$$\tilde{\theta}_2 = \underbrace{\frac{n}{n-1}}_{\text{done}} \hat{\theta}_2 \Rightarrow E[\tilde{\theta}_2] = \sigma^2$$

$$\tilde{\theta}_2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$\hat{\sigma}^2 = \begin{cases} \frac{1}{n} \sum_{i=1}^n (x_i - m)^2 & \text{si } m \text{ est connue} \\ \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 & \text{si } m \text{ est inconnue} \\ \bar{x} = \frac{1}{n} \sum x_i \end{cases}$$

Vraisemblance

$$x_i \sim N(m, \sigma^2)$$

$$\sigma^2 \text{ connue}$$

$$\theta = m \in \mathbb{R}$$

$$L(x_1, \dots, x_n; \theta) = p(x_1, \dots, x_n; \theta)$$

$$= \prod_{i=1}^n \left[ \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left( -\frac{(x_i - m)^2}{2\sigma^2} \right) \right]$$

$x_1, \dots, x_n$  ind

$$= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp \left[ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m)^2 \right]$$

$$L(x_1, \dots, x_n; \theta) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp \left[ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m)^2 \right]$$

$$\ln L = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m)^2$$

$$\frac{\partial \ln L}{\partial m} = -\frac{1}{\sigma^2} \sum_{i=1}^n (x_i - m) (-1) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - m)$$

$$\frac{\partial^2 \ln L}{\partial m^2} = \frac{1}{\sigma^2} \sum_{i=1}^n (-1) = -\frac{n}{\sigma^2}$$

$$E\left[\frac{\partial^2 \ln L}{\partial m^2}\right] = E\left[-\frac{n}{\sigma^2}\right] = -\frac{n}{\sigma^2}$$

Pour un estimateur non biaisé de  $m$ , la borne de Cramér-Rao

$$\text{var } B(R(m)) = \frac{(1+0)^2}{-\left[-\frac{n}{\sigma^2}\right]} = \boxed{\frac{\sigma^2}{n}}$$

On a donc tout à l'heure que

$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i \text{ est un estimateur de } m \text{ non biaisé et de variance } \text{Var}(\hat{\theta}) = \frac{\sigma^2}{n} = B(R(m))$$

Cours du 16/11/2022

$$\begin{aligned} E[(\hat{\theta} - \theta)^2] &= E\left[ (\hat{\theta} - E[\hat{\theta}] + \overbrace{E[\hat{\theta}] - \theta}^{\text{Var } \hat{\theta}})^2 \right] \\ &= \underbrace{E((\hat{\theta} - E[\hat{\theta}])^2)}_{\text{Var } \hat{\theta}} + b_n(\theta) + 2 \underbrace{E[\hat{\theta} - E[\hat{\theta}]]}_{0} \end{aligned}$$

$$A = \text{cov}(\hat{\theta}) = \begin{pmatrix} \text{var } \hat{a} & \text{cov}(\hat{a}, \hat{b}) & \times \\ \times & \text{var } \hat{b} & \times \\ \times & \times & \text{var } \hat{\sigma}^2 \end{pmatrix} \geq \begin{pmatrix} B = \bar{I}_n'(\theta) \\ \begin{pmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \\ b_{31} & b_{32} & b_{33} \end{pmatrix} \end{pmatrix}$$

$$\hat{\theta} = \begin{pmatrix} \hat{a} \\ \hat{b} \\ \hat{\sigma}^2 \end{pmatrix}$$

$$x^T (A - B)x \geq 0 \quad \forall x \in \mathbb{R}^3$$

$$x = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \quad (1 \ 0 \ 0) \underbrace{\begin{pmatrix} \text{Var } \hat{\alpha} - b_{11} & x & x \\ x & \text{Var } \hat{\beta} - b_{22} & x \\ x & x & \text{Var } \hat{\delta} - b_{33} \end{pmatrix}}_{(1 \ 0 \ 0)} \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \geq 0$$

$$\Rightarrow \text{Var } \hat{\alpha} - b_{11} \geq 0 \quad \text{and} \quad \boxed{\text{Var } \hat{\alpha} \geq b_{11}}$$

$$x = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}$$

$$\boxed{\text{Var } \hat{\beta} \geq b_{22}}$$

$$x = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

$$\boxed{\text{Var } \hat{\delta} \geq b_{33}}$$

Example

$$x_i \sim N(m, \sigma^2) \quad \theta = \begin{pmatrix} m \\ \sigma^2 \end{pmatrix}$$

$$\boxed{\text{Var } \hat{m} \geq ?} \quad \boxed{\text{Var } \hat{\sigma}^2 \geq ?}$$

$$J_n(\theta) = \begin{pmatrix} E\left[-\frac{\partial^2 \ln L}{\partial m^2}\right] & E\left(-\frac{\partial^2 \ln L}{\partial \sigma^2 \partial m}\right) \\ -\frac{\partial}{\partial \sigma^2} & X \\ & E\left[\frac{-\partial^2 \ln L}{\partial (\sigma^2)^2}\right] \end{pmatrix}$$

$$\ln L = -\frac{n}{2} \ln(\sigma^2) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m)^2$$

$$\frac{\partial \ln L}{\partial \sigma^2} = 0 - \frac{n}{2} \frac{1}{\sigma^2} + \frac{1}{2} \frac{1}{\sigma^4} \sum_{i=1}^n (x_i - m)^2$$

$$\frac{\partial^2 \ln L}{\partial \sigma^2} = \frac{n}{2\sigma^4} + \frac{1}{2} \left( -\frac{2}{\sigma^6} \right) \sum_{i=1}^n (x_i - m)^2$$

$$E\left[ \frac{\partial^2 \ln L}{\partial \sigma^2} \right] = \frac{n}{2\sigma^4} - \underbrace{\frac{1}{\sigma^6} \sum_{i=1}^n E\left[ \frac{(x_i - m)^2}{\sigma^2} \right]}_{-\frac{n}{\sigma^4} = -\frac{2n}{2\sigma^4}} = \boxed{-\frac{n}{2\sigma^4}}$$

$$\frac{\partial^2 \ln L}{\partial m \partial \sigma^2} = 0 + \frac{1}{2\sigma^4} \sum_{i=1}^n 2(x_i - m) (-1)$$

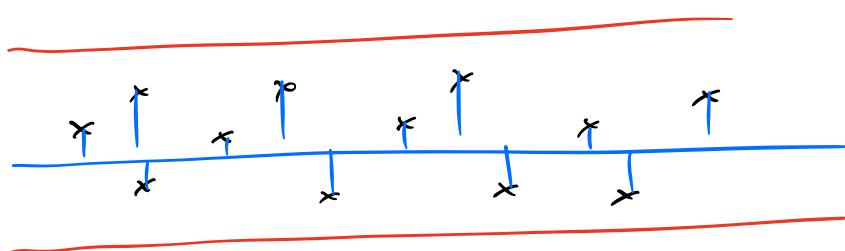
$$E\left[ \frac{\partial^2 \ln L}{\partial m \partial \sigma^2} \right] = -\frac{1}{\sigma^4} \sum_{i=1}^n (E[x_i] - m) = \boxed{0}$$

$$I_n(\theta) = \begin{bmatrix} \frac{n}{\sigma^2} & 0 \\ 0 & \frac{n}{2\sigma^4} \end{bmatrix}$$

$$I_n^{-1}(\theta) = \begin{bmatrix} \frac{\sigma^2}{n} & 0 \\ 0 & \frac{2\sigma^4}{n} \end{bmatrix}$$

$$\boxed{\text{Var } \hat{m} \geq \frac{\sigma^2}{n}}$$

$$\boxed{\text{Var } \hat{\sigma}^2 \geq \frac{2\sigma^4}{n}}$$



## Estimateur du max de vraisemblance

Ex1  $x_i \sim N(m, \sigma^2)$   $\theta = (\begin{matrix} m \\ \sigma^2 \end{matrix})$

$$L(x_1, \dots, x_n; \theta) = -\frac{n}{2} \ln 2\pi - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m)^2$$

$$\frac{\partial \ln L}{\partial m} = 0 \iff -\frac{1}{2\sigma^2} \sum_{i=1}^n 2(x_i - m)(-1) = 0$$

$$\iff \sum x_i - nm = 0 \iff m = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\frac{\partial \ln L}{\partial \sigma^2} = 0 \iff -\frac{n}{2} \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - m)^2 = 0$$

$$\iff n\sigma^2 = \sum_{i=1}^n (x_i - m)^2$$

$$\iff \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - m)^2$$

L'estimateur du max de vraisemblance de  $\theta$  vérifie

$$\left\{ \begin{array}{l} m = \frac{1}{n} \sum_{i=1}^n x_i \\ \sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - m)^2 \end{array} \right.$$

$$\Rightarrow \left\{ \begin{array}{l} \hat{m} = \frac{1}{n} \sum_{i=1}^n x_i \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{m})^2 \end{array} \right.$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{m})^2$$

Exemple 1

$$x_i \sim P(\lambda) \quad \theta = (\lambda)$$

$$P[x_i = x_i] = \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \quad x_i \in \mathbb{N}$$

Quel est l'estimateur du maximum de vraisemblance de  $\lambda$ ?

Vraisemblance

$$L(x_1, \dots, x_n; \lambda) = \prod_{i=1}^n \left( \frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right)$$

$$= \boxed{\frac{\lambda^{\sum x_i}}{\prod x_i!} e^{-n\lambda}}$$

log-vraisemblance

$$\ln L = (\sum x_i) \ln \lambda - \ln(\prod x_i!) - n\lambda$$

$$\frac{\partial \ln L}{\partial \lambda} = \frac{\sum x_i}{\lambda} + o - n = 0$$

$$\boxed{\lambda = \frac{1}{n} \sum_{i=1}^n x_i}$$

$$\hat{\lambda}_{MV} = \frac{1}{n} \sum_{i=1}^n x_i$$

Invariance Fonctionnelle

$$\left[ x_i \sim N(\mu, \sigma^2) \right]$$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2$$

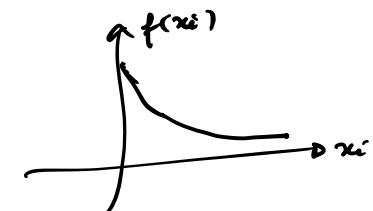
Quel est l'estimateur du maximum de vraisemblance de  $\sigma$  ?

$$\begin{aligned} \sigma &= \sqrt{\sigma^2} \\ &= h(\sigma^2) \end{aligned}$$

$$\Rightarrow \boxed{\hat{\sigma}_{MV} = h(\hat{\sigma}_{MV}^2)}$$

$$\text{ta: } \boxed{\hat{\sigma}_{MV} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2}}$$

Méthode des moments.



$$x_i \sim G(\theta, v)$$

$$f(x_i) = \frac{\theta^v}{\Gamma(v)} e^{-\theta x_i} x_i^{v-1} \quad x_i > 0$$

( $\theta$ ) Estimations de  $\theta$  et de  $v$  ?



$$\left\{ \begin{array}{l} E(x_i) = m_1 = \frac{v}{\theta} \\ E(x_i^2) = m_2 = \frac{v}{\theta^2} + \frac{v^2}{\theta^2} \end{array} \right. \Rightarrow \left\{ \begin{array}{l} v = \theta m_2 \\ m_2 = \frac{\theta m_1}{\theta^2} + \frac{\theta^2 m_1^2}{\theta^2} \end{array} \right.$$

$\uparrow$   
 $\text{Var } x_i + E(x_i)^2$

$$\Rightarrow \left\{ \frac{1}{\theta} = \frac{m_2 - m_1^2}{m_1} \right. \Rightarrow \boxed{\theta = \frac{m_1}{m_2 - m_1^2}}$$

$\uparrow$

$$v = \theta m_1 = \boxed{\frac{m_1^2}{m_2 - m_1^2} = v}$$

$\uparrow$

$$E(x_i) \approx \frac{1}{n} \sum_{i=1}^n x_i$$

$$E(x_i^2) \approx \frac{1}{n} \sum_{i=1}^n x_i^2$$

Dans cet exemple

$$\boxed{\hat{\theta}_{no} = \frac{\frac{1}{n} \sum x_i}{\frac{1}{n} \sum x_i^2 - \left( \frac{1}{n} \sum x_i \right)^2}}$$

$$\boxed{\hat{v}_{no} = \frac{\left( \frac{1}{n} \sum x_i \right)^2}{\frac{1}{n} \sum x_i^2 - \left( \frac{1}{n} \sum x_i \right)^2}}$$

$\frac{1}{n}$

Example 2

$$x_i \sim N(m, \sigma^2) \quad \theta = \begin{pmatrix} m \\ \sigma^2 \end{pmatrix}$$

$$\left\{ \begin{array}{l} E(x_i) = m \\ E(x_i^2) = \sigma^2 + m^2 \end{array} \Rightarrow \begin{array}{l} m = m_1 \\ \sigma^2 = m_2 - m_1^2 \end{array} \right.$$

$$\hat{m}_{\text{ML}} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\hat{\sigma}_{\text{ML}}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{m})^2$$

$$\hat{m}_{\text{MO}} = \frac{1}{n} \sum_{i=1}^n x_i$$

$$\hat{\sigma}_{\text{MO}}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \left( \frac{1}{n} \sum_{i=1}^n x_i \right)^2$$

[Cours du 23/01/2022]

Bayes

$$P(A|B) = \frac{\overbrace{P(B|A)}^{\text{vraisemblance}} P(A)}{P(B)}$$

$$A = \theta$$

$$B = (x_1, \dots, x_n)$$

$$P(\theta|x_1, \dots, x_n) = \frac{P(x_1, \dots, x_n|\theta) P(\theta)}{P(x_1, \dots, x_n)}$$

loi a posteriori

Estimateur MAP = estimateur du maximum a posteriori

$$P(B) = \int \underbrace{P(A|B) dA}_{P(B|A) P(A)}$$

$$P(x_1, \dots, x_n) = \int P(x_1, \dots, x_n|\theta) P(\theta) d\theta$$

$$P(\theta|x_1, \dots, x_n) \propto P(x_1, \dots, x_n|\theta) P(\theta)$$

$$x_i \sim N(\theta, \sigma^2) \Rightarrow \text{joint density} \quad \prod_{i=1}^n f(x_i | \theta)$$

$$f(x_i | \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \theta)^2}{2\sigma^2}\right)$$

$$p(x_1, \dots, x_n | \theta) = \frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2\right)$$

Likelihood

$$\theta \sim N(\mu, v^2) \Rightarrow p(\theta) = \frac{1}{\sqrt{2\pi v^2}} \exp\left(-\frac{(\theta - \mu)^2}{2v^2}\right)$$

Estimator MAP

$$\hat{\theta}_{MAP} = \arg \max_{\theta} [p(x_1, \dots, x_n | \theta) p(\theta)]$$

$$= \arg \max_{\theta} [\ln p(x_1, \dots, x_n | \theta) + \ln p(\theta)]$$

$$\ln p = K - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2 - \frac{1}{2v^2} (\theta - \mu)^2$$

$$\frac{\partial \ln p}{\partial \theta} = 0 \Leftrightarrow \cancel{\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)} - \cancel{\frac{1}{2v^2} (\theta - \mu)} = 0$$

$$\frac{1}{\sigma^2} \sum_{i=1}^n x_i - \frac{n\theta}{\sigma^2} - \frac{\theta}{v^2} + \frac{\mu}{v^2} = 0$$

$$\theta \left( \frac{n}{\sigma^2} + \frac{1}{v^2} \right) = \underbrace{\frac{1}{\sigma^2} \sum_{i=1}^n x_i}_{\frac{n\sigma^2 + v^2}{\sigma^2 v^2}} + \frac{\mu}{v^2}$$

$$x_i | \theta \sim N(\theta, \sigma^2)$$

$$\theta = \frac{n\sigma^2}{n\sigma^2 + v^2} \cancel{\sum_{i=1}^n x_i} + \frac{\sigma^2}{n\sigma^2 + v^2} \mu$$

$$\theta \sim N(\mu, v^2)$$

$$\hat{\theta}_{MAP} = \frac{n\sigma^2}{n\sigma^2 + v^2} \left( \frac{1}{n} \sum_{i=1}^n x_i \right) + \frac{\sigma^2}{n\sigma^2 + v^2} \mu$$

hinde  $\theta | x_1, \dots, x_n$  :

$$p(\theta | x_1, \dots, x_n) \propto \exp \left[ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \theta)^2 - \frac{1}{2\nu^2} (\theta - \mu)^2 \right]$$

$$\exp(-a\theta^2 + b\theta + c) \approx \exp \left( -\frac{(\theta - m_\theta)^2}{2\sigma_\theta^2} \right)$$

$$\begin{aligned} & \exp \left[ -a \left( \theta + \frac{b}{a} \theta + \frac{c}{a} \right) \right] \\ & \exp \left( -\frac{(\theta - m_\theta)^2}{2\sigma_\theta^2} \right) \end{aligned}$$

coeff de  $\theta^2$

$$+\frac{1}{\sigma_\theta^2} = +\frac{n}{2\sigma^2} + \frac{1}{2\nu^2}$$

$$\frac{1}{\sigma_\theta^2} = \frac{n\nu^2 + \sigma^2}{\sigma^2\nu^2}$$

$$\boxed{\sigma_\theta^2 = \frac{\sigma^2\nu^2}{n\nu^2 + \sigma^2}}$$

coeff de  $\theta$

$$-\frac{1}{\sigma_\theta^2} (-2m_\theta) = -\frac{1}{2\sigma^2} \left( -2 \sum_{i=1}^n x_i \right) - \frac{1}{2\nu^2} (-2\nu)$$

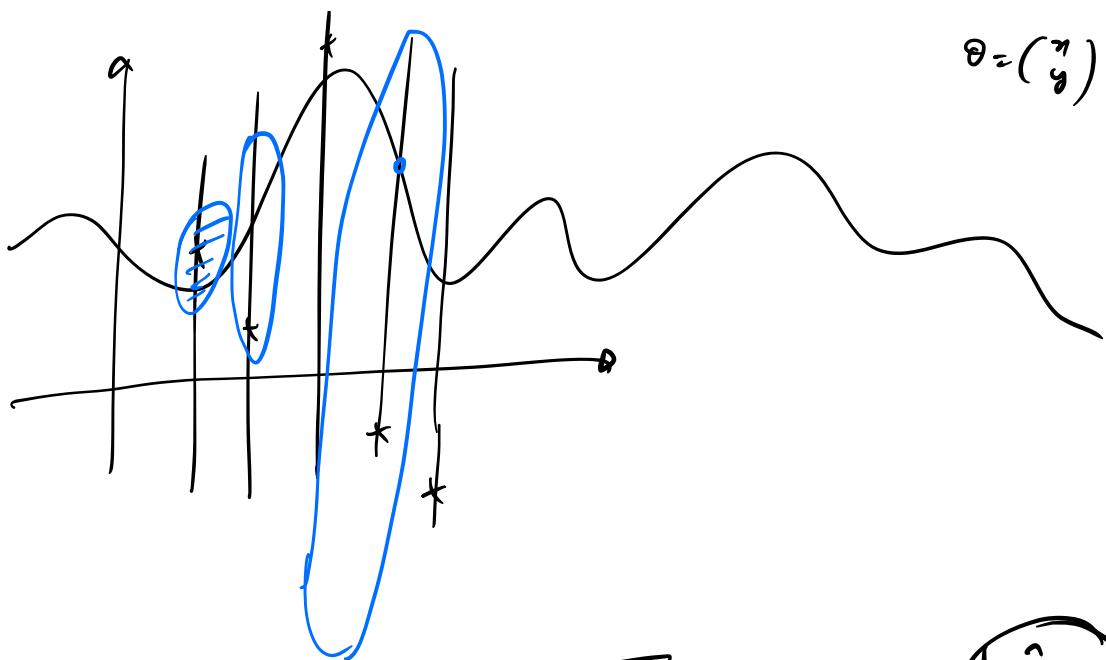
$$m_\theta = \frac{\sigma^2\theta}{\sigma^2} \sum_{i=1}^n x_i + \frac{\sigma^2\theta}{\nu^2} \mu$$

i.e.

$$\boxed{m_\theta = \frac{\nu^2}{n\nu^2 + \sigma^2} \sum_{i=1}^n x_i + \frac{\sigma^2}{n\nu^2 + \sigma^2} \mu}$$

i.e.

$$\boxed{E[\theta | x_1, \dots, x_n] = m_\theta = \hat{\theta}_{\text{MMSE}} = \hat{\theta}_{\text{MAP}}}$$



Intervalle de Confiance  $\hat{\theta}_{EZ}$

$x_i \sim N(\mu, \sigma^2)$   
intervalle de confiance  
pour  $\theta = m$

Étape 1 : on cherche un estimateur  $\hat{\theta}$

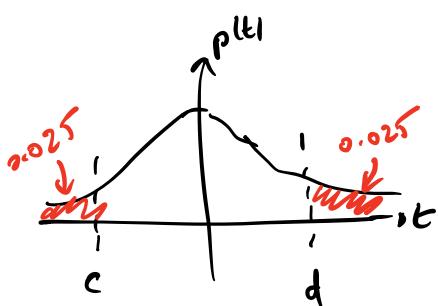
$$\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i$$



Étape 2 : on va chercher la loi de l'estimateur

$$\hat{\theta} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Étape 3 : on en déduit une statistique  $T$  de loi indépendante des paramètres  $\theta$



$$T = \frac{\frac{1}{n} \sum_{i=1}^n x_i - \mu}{\sqrt{\sigma^2/n}} \sim N(0, 1)$$

$$P[c < T < d] = 0.95$$

$$c = ?$$

$$F(c) = 0.025$$

$$c = F^{-1}(0.025)$$

$$d = -c = F^{-1}(0.95 + 0.025)$$

Étape 4 : on en déduit l'intervalle de confiance

$$c < T = \frac{\frac{1}{n} \sum x_i - m}{\sqrt{\sigma^2/n}} < d \text{ avec proba } 0.95$$

$$c \frac{\sigma}{\sqrt{n}} < \frac{1}{n} \sum x_i - m < d \frac{\sigma}{\sqrt{n}}$$

$$\boxed{\frac{1}{n} \sum x_i - \frac{d\sigma}{\sqrt{n}} < m < \frac{1}{n} \sum x_i - c \frac{\sigma}{\sqrt{n}}}$$



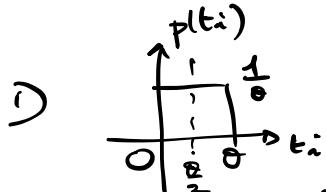
[TD du 23/11/2022]

$$\text{Biass } b_n(\theta) = E[\hat{\theta}] - \theta$$

$$\text{Variane } \text{Var}_n(\theta) = E[(\hat{\theta} - E[\hat{\theta}])^2] = \text{Var } \hat{\theta}$$

Erreur Quadratique moyenne

$$E[(\hat{\theta} - \theta)^2] = b_n^2(\theta) + \text{Var}_n(\theta)$$



$$E(T_i) = \int_0^\theta \frac{t_i}{\theta} dt_i = \frac{1}{\theta} \frac{\theta^2}{2} = \boxed{\frac{\theta^2}{2}}$$

$$\text{Var } T_i = E(T_i^2) - E(T_i)^2 \quad \left| \quad E(T_i^2) = \int_0^\theta \frac{1}{\theta} t_i^2 dt_i = \frac{1}{\theta} \frac{\theta^3}{3} = \frac{\theta^2}{3} \right.$$

$$= \frac{\theta^2}{3} - \frac{\theta^2}{4} = \boxed{\frac{\theta^2}{12}}$$

2)  $\bar{T} = \frac{1}{n} \sum_{i=1}^n T_i$

$$E(\bar{T}) = \frac{1}{n} \sum_{i=1}^n \frac{\theta^2}{2} = \boxed{\frac{\theta^2}{2}}$$

$$\text{Var}(\bar{T}) = \text{var}\left(\frac{1}{n} \sum T_i\right) = \frac{1}{n^2} \text{var}(\sum T_i) = \frac{1}{n^2} \sum_{i=1}^n \text{Var} T_i = \frac{\text{Var}(T_i)}{n}$$

$$= \frac{\theta^2}{12n} \quad \boxed{\theta^2 / 12n}$$

$\bar{T}$  est un estimateur biasé de  $\theta$

mais on peut enlever le bias en posant

$$\hat{\theta}_1 = 2\bar{T}$$

$\dots \dots \dots \theta \dots \dots$

$$E(\hat{\theta}_1) = 2\tau(\tau) = 2 \cdot \frac{1}{2} = 1$$

$\hat{\theta}_1$  est un estimateur non biaisé de  $\theta$

$$\text{Var}(\hat{\theta}_1) = \text{Var}(2\bar{T}) = 4 \text{Var}\bar{T} = \boxed{\frac{\theta^2}{3n}}$$

$$\left( \begin{array}{l} \text{Var}(\hat{\theta}_1) \xrightarrow[n \rightarrow +\infty]{} 0 \\ E(\hat{\theta}_1) - \theta \xrightarrow[n \rightarrow +\infty]{} 0 \end{array} \right) \Rightarrow \boxed{\hat{\theta}_1 \text{ est un estimateur convergent de } \theta}$$

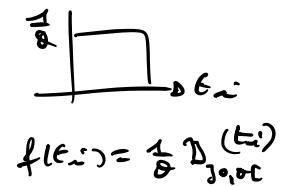
Remarque  $E(X_i) = \frac{\theta}{2} \Rightarrow \theta = 2E(X_i)$

et  $\hat{\theta}_1 = \frac{2}{n} \sum_{i=1}^n X_i$

C'est l'estimateur des moments de  $\theta$  !!

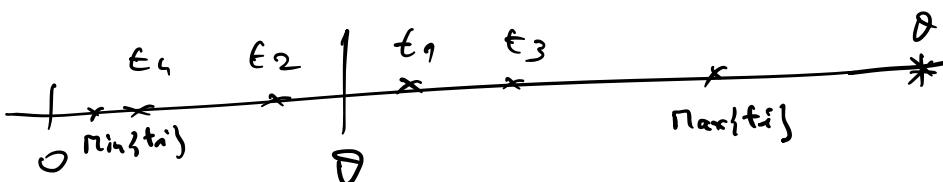
### 3) Estimateur du max de recouvrance

$$\hat{\theta}_{\text{rec}} = \underset{\theta}{\operatorname{argmax}} \ L(t_1, \dots, t_n; \theta)$$



$$L(t_1, \dots, t_n) = \frac{1}{\theta^n} \prod_{i=1}^n I_{[0, \theta]}(t_i)$$

$$I_{[0, \theta]}(t_i) = 1 \Leftrightarrow 0 < t_i < \theta \quad \forall i$$



$$\hat{\theta}_{\text{rec}} = \max_{i \in \{1, \dots, n\}} \{t_i\}$$

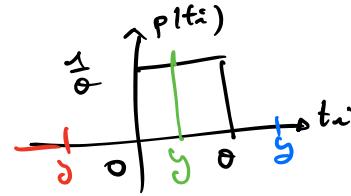
$$\text{Soit } Y_n = \sup_i t_i$$

Determiner la fonction de répartition de  $Y_n$  en remarquant que  $y_n < y \Leftrightarrow t_i < y \quad \forall i = 1, \dots, n$

En déduire la loi de  $Y_n$ , sa moyenne et sa variance

$$P(Y_n < y) = P(T_1 < y, T_2 < y, \dots, T_n < y)$$

$$= \prod_{i=1}^n P(T_i < y) \quad T_i \sim U(0, \theta)$$



donc  $P(T_i < y) = \begin{cases} 0 & y \leq 0 \\ 1 & y \geq \theta \\ \int_0^y \frac{1}{\theta} dt_i & y \in ]0, \theta[ \end{cases}$

donc  $P(Y_n < y) = \prod_{i=1}^n \int_0^y \frac{1}{\theta} dt_i \quad y \in ]0, \theta[$

Donc  $P(Y_n < y) = \prod_{i=1}^n \begin{cases} 0 & y \leq 0 \\ \left(\frac{y}{\theta}\right)^n & y \in ]0, \theta[ \\ 1 & y \geq \theta \end{cases}$

$$= \begin{cases} 0 & y \leq 0 \\ \left(\frac{y}{\theta}\right)^n & y \in ]0, \theta[ \\ 1 & y \geq \theta \end{cases}$$

La densité de  $Y_n$  va donc

$$P(y_n) = \begin{cases} \frac{ny^{n-1}}{\theta^n} & y \in ]0, \theta[ \\ 0 & \text{sinon} \end{cases}$$

Moyenne  $E(Y_n) = \int_0^\theta y \times \frac{ny^{n-1}}{\theta^n} dy = \frac{n}{\theta^n} \left[ \frac{y^{n+1}}{n+1} \right]_0^\theta = \frac{n\theta}{n+1}$

Variance  $\text{Var} Y_n = E(Y_n^2) - E(Y_n)^2$

$$E(Y_n^2) = \int_0^\theta y^2 \frac{ny^{n-1}}{\theta^n} dy = \frac{n}{\theta^n} \left[ \frac{y^{n+2}}{n+2} \right]_0^\theta = \frac{n}{n+2} \theta^2$$

$$\text{Var}Y_n = \frac{n}{n+2}\theta^2 - \frac{n^2}{(n+1)^2}\theta^2 = \frac{n\theta^2[(n+1)^2 - n(n+2)]}{(n+2)(n+1)^2}$$

donc

$$\boxed{\text{Var}Y_n = \frac{n}{(n+2)(n+1)^2}\theta^2}$$

$\hat{\theta}_1$  n'est pas un estimateur biaisé de  $\theta$  car  $E[Y_n] = \frac{n}{n+2}\theta \neq \theta$

On enlève le biais en construisant

$$\hat{\theta}_2 = \frac{n+1}{n}Y_n = \frac{n+1}{n} \sum_i T_i$$

Par construction,  $\hat{\theta}_2$  est un estimateur non biaisé de  $\theta$  !

[Montrer que  $\hat{\theta}_2$  n'est un estimateur convergent de  $\theta$   
Choisir entre  $\hat{\theta}_1$  et  $\hat{\theta}_2$ ? Pourquoi?]

$$\begin{aligned} \text{Var} \hat{\theta}_2 &= \frac{(n+1)^2}{n^2} \text{Var} Y_n = \frac{\theta^2}{n(n+2)} \xrightarrow[n \rightarrow +\infty]{\rightarrow 0} \theta \\ E[\hat{\theta}_2] - \theta &= 0 \xrightarrow[n \rightarrow +\infty]{\rightarrow 0} \sim \frac{\theta^2}{n^2} \quad \text{estimateur convergent} \\ E[\hat{\theta}_1] - \theta &= 0 \\ \text{Var} \hat{\theta}_1 &= \frac{\theta^2}{3n} \end{aligned}$$

Donc préférer  $\hat{\theta}_2$  qui converge plus vite que  $\hat{\theta}_1$ .

[Exo3]

$$f(x_i) = \begin{cases} \beta e^{\beta(x-x_i)} & x \in ]\bar{x}, +\infty[ \\ 0 & \text{sinon } (x \leq \bar{x}) \end{cases}$$

- 1) Estimateur du max de vraisemblance de  $\omega = \frac{1}{\beta}$  ? ( $\omega$  connu)  
Montrer que cet estimateur est sans biais et convergent  
Est. il suffit

2) même travail avec  $\alpha$  ( $\beta$  connu)

Rq

$$\begin{aligned} Y_i &= X_i - \alpha \sim \Sigma(\beta) \\ E[Y_i] &= \frac{1}{\beta} = \omega \quad \boxed{\text{Tadis}} \\ \text{Var}(Y_i) &= \frac{1}{\beta^2} = \omega^2 \end{aligned}$$

$$g(y_i) = \begin{cases} \beta e^{-\beta y_i} & y_i > 0 \\ 0 & \text{sinon} \end{cases}$$

Loi exponentielle ou loi gamma

$$\text{d) } \underline{\text{Vraies valeurs}} \quad \omega = \frac{1}{\beta}$$

Méthode 1

$$L(x_1, \dots, x_n; \omega) = \frac{1}{\omega^n} e^{\sum_{i=1}^n \frac{1}{\omega} (x_i - \alpha)}$$

$$\ln L = -n \ln \omega + \frac{1}{\omega} \sum_{i=1}^n (x_i - \alpha)$$

$$\frac{\partial \ln L}{\partial \omega} = 0 \iff \left[ \frac{-n}{\omega} - \frac{1}{\omega^2} \sum_{i=1}^n (x_i - \alpha) = 0 \right]$$

$$\text{donc } \omega = \frac{1}{n} \sum_{i=1}^n (x_i - \alpha)$$

$$\boxed{\hat{\omega}_{MV} = \frac{1}{n} \sum_{i=1}^n (x_i - \alpha)}$$

$$E[x_i - \alpha] \\ \text{var}(x_i - \alpha) = \text{var } x_i$$

$$\underline{\text{Biass}} \quad E[\hat{\omega}_{MV}] - \omega$$

$$E[\hat{\omega}_{MV}] = \frac{1}{n} \sum_{i=1}^n \underbrace{\frac{E[Y_i]}{\omega}}_{=1} = \omega \quad \text{donc}$$

$\hat{\omega}_{MV}$  estimeur non biaisé de  $\omega$

$$\underline{\text{Variance}} \quad \text{Var } \hat{\omega}_{MV} = \frac{1}{n^2} \sum_{i=1}^n \underbrace{\text{Var}(x_i - \alpha)}_{\text{Var } Y_i} = \frac{\text{Var}[Y_i]}{n} = \frac{\omega^2}{n}$$

$$\text{Var } \hat{\omega} = \frac{\omega^2}{n} \xrightarrow{n \rightarrow \infty} 0 \\ E[\hat{\omega}] - \omega = 0 \xrightarrow{n \rightarrow \infty} 0$$

$\hat{\omega}_{MV}$  estimeur convergent

$$\underline{\text{Efficacité}} \quad \boxed{\text{Var } \hat{\omega}_{MV} = \text{BCR}} ?$$

$$\text{BCR} = \frac{\left[ 1 + b_n(\omega) \right]^2}{E \left[ - \frac{\partial^2 \ln L(x_1, \dots, x_n; \omega)}{\partial \omega^2} \right]}$$

$$\text{ici } b_n(\omega) = 0 \Rightarrow \boxed{\text{Numérateur} = 1}$$

$$\frac{\partial \ln L}{\partial \omega} = \frac{-n}{\omega} - \frac{1}{\omega^2} \sum_{i=1}^n (\alpha - x_i)$$

$$\frac{\partial^2 \ln L}{\partial \omega^2} = \frac{n}{\omega^2} + \frac{2}{\omega^3} \sum_{i=1}^n (\alpha - x_i)$$

$$\begin{aligned} E\left[\frac{\partial^2 \ln L}{\partial \omega^2}\right] &= \frac{n}{\omega^2} + \frac{2}{\omega^3} \sum_{i=1}^n -E\left[\frac{x_i - \alpha}{\lambda_i}\right] \\ &= \frac{n}{\omega^2} + \frac{-2n\omega}{\omega^3} = -\frac{n}{\omega^2} \end{aligned}$$

$$BCR = \frac{1}{-\left(\frac{-n}{\omega^2}\right)} = \frac{\omega^2}{n}$$

$$\text{Var } \hat{\omega}_{MV} = BCR$$

$\hat{\omega}_{MV}$  non biaisé

donc  $\hat{\omega}_{MV}$  est l'estimateur efficace de  $\omega$

## Cours du 30/01/2022 |

(H<sub>0</sub>) pas d'anomalie = fonctionnement normal

(H<sub>1</sub>) anomalie = problème

$$\alpha = P[\text{Rejeter } H_0 \mid \text{H_0 vraie}] = P[\text{décider qu'on a une anomalie} \mid \text{on n'a pas d'anomalie}]$$

$$= PFA = \text{probabilité de fausse alarme}$$

$$\beta = P[\text{Rejeter } H_1 \mid H_1 \text{ vraie}] = P[\text{décider qu'on a une anomalie} \mid \text{on n'a pas d'anomalie}]$$

$$= PND = \text{probabilité de non-détection}$$

$$\pi = 1 - \beta = P[\text{Accepter } H_1 \mid H_1 \text{ vraie}] = P[\text{décider qu'on a une anomalie} \mid \text{on a une anomalie}]$$

$= P_D$  = probabilité de détection

Exemple

$$X_i \sim N(m, \sigma^2)$$

$H_0$

$$m = m_0$$

(moyenne "petite")

$$\begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}^\top \xrightarrow{\sigma^2 \text{ connue}}$$

$H_1$

$$m = m_1 > m_0$$

(moyenne "grande")

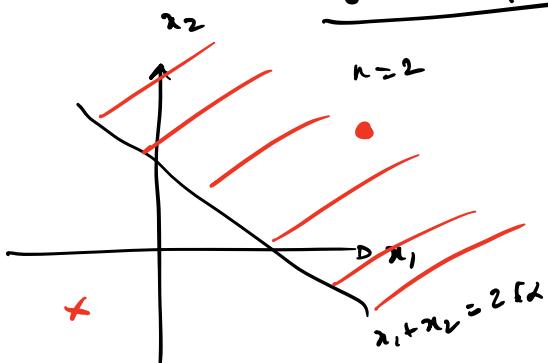
$$\text{Rejet de } H_0 \text{ si } T = \frac{1}{n} \sum_{i=1}^n x_i > \text{Seuil} = S_x$$

Statistique de test

$$T = \frac{1}{n} \sum_{i=1}^n x_i$$

Réglion critique d'après

$$\left\{ (x_1, \dots, x_n) / \frac{1}{n} \sum_{i=1}^n x_i > S_x \right\}$$



$$x_1 + x_2 > 2S_x$$

=  $\boxed{\text{V}}$

Question : comment calculer  $\alpha$  et  $\beta$ ?

$$\alpha = P(\text{Rejet de } H_0 \mid H_0 \text{ vraie})$$

$$= P\left(\frac{1}{n} \sum_{i=1}^n x_i > S_x \mid m = m_0\right)$$

$$= 1 - P\left(\frac{1}{n} \sum_{i=1}^n x_i \leq S_x \mid m = m_0\right)$$

$$U = \frac{\frac{1}{n} \sum x_i - m}{\sqrt{\sigma^2/n}} \leq \frac{S_x - m}{\sqrt{\sigma^2/n}}$$

Fonction de répartition.

$$\sim N(0,1) \quad X_i \sim N(m, \sigma^2) \Rightarrow \frac{1}{n} \sum_{i=1}^n x_i \sim N\left(m, \frac{\sigma^2}{n}\right)$$

$$\begin{aligned} \text{Var}\left(\frac{1}{n} \sum x_i\right) &= \frac{1}{n^2} \text{Var}\left(\sum x_i\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n \text{Var} \frac{x_i}{\sigma^2} = \frac{n \sigma^2}{n^2} \end{aligned}$$

$$F(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-u^2/2} du$$

fonction de la répartition de  
la loi normale  $N(0,1)$

$$\frac{1}{n} \sum_{i=1}^n x_i \sim N\left(m, \frac{\sigma^2}{n}\right) \Leftrightarrow \frac{\bar{x} - m}{\sqrt{\frac{\sigma^2}{n}}} \sim N(0,1)$$

on centre et on reduit

$$\alpha = 1 - P\left[ \frac{\frac{1}{n} \sum x_i - m}{\sqrt{\frac{\sigma^2}{n}}} \leq \frac{s_d - m}{\sqrt{\frac{\sigma^2}{n}}} \mid m = m_0 \right]$$

$$\alpha = 1 - F\left[ \frac{s_d - m_0}{\sqrt{\frac{\sigma^2}{n}}} \right] \quad F\left( \sqrt{n} \frac{s_d - m_0}{\sqrt{\sigma^2}} \right)$$

$\sim N(0,1)$

Réq:  $\alpha$  dépend du seuil noté  $s_d$ , de  $m_0$  (valeur du  $\theta$  sous  $H_0$ ),  $n$  nombre de données, et de  $\sigma^2$  (variance des données)



Calcul de  $\beta$

$$\beta = P[\text{Rejet de } H_0 \mid H_1 \text{ vraie}]$$

$$= P\left[ T = \frac{1}{n} \sum_{i=1}^n x_i < s_d \mid m = m_1 \right]$$

$$= P\left[ \frac{\bar{x} - m}{\sqrt{\frac{\sigma^2}{n}}} < \frac{s_d - m}{\sqrt{\frac{\sigma^2}{n}}} \mid m = m_1 \right]$$

$$\beta = F\left[ \frac{s_d - m_1}{\sqrt{\frac{\sigma^2}{n}}} \right]$$

$$\left[ 1 - \frac{\sigma^2}{\sqrt{n}} \right]$$

En pratique, pour faire le test, il faut se fixer  
soit  $\alpha$ , soit  $\beta$ .

En strat, on se fixe  $\alpha \xrightarrow{0.01}$   
 $\rightarrow 0.05$  | on en déduit  
le seuil  $s_\alpha$  et ensuite on calcule  $\beta$

$$\begin{cases} \alpha = 1 - F\left(\frac{s_\alpha - m_0}{\sqrt{\sigma^2/n}}\right) & \text{on se fixe } \alpha \\ \beta = F\left(\frac{s_\alpha - m_1}{\sqrt{\sigma^2/n}}\right) & (2) \Rightarrow \beta \end{cases}$$

Valeur du seuil

$$F\left(\frac{s_\alpha - m_0}{\sqrt{\sigma^2/n}}\right) = 1 - \alpha$$

$$\Rightarrow \frac{s_\alpha - m_0}{\sqrt{\sigma^2/n}} = \bar{F}'(1 - \alpha)$$

$$s_\alpha = m_0 + \sqrt{\sigma^2/n} \bar{F}'(1 - \alpha)$$



Courbes COR

$$\pi = f(\alpha)$$

$$\beta = F\left(\frac{\alpha - m_1}{\sqrt{\sigma^2/n}}\right) \leftarrow$$

$$\pi = 1 - \beta = 1 - F\left(\frac{m_0 - m_1}{\sqrt{\sigma^2/n}} + \bar{F}'(1-\alpha)\right)$$

$$\frac{\sqrt{n}}{\sigma} (m_0 - m_1) = -\frac{\sqrt{n}}{\sigma} (\underbrace{m_1 - m_0}_{\leq 0})$$

NEYMAN-PEARSON

$$X_i \sim N(m, \sigma^2)$$

$$H_0: m = m_0$$

$$H_1: m = m_1 > m_0$$

Rejet de  $H_0$  si  $\frac{\frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m_1)^2\right]}{\frac{1}{(2\pi\sigma^2)^{n/2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m_0)^2\right]} \leq \alpha$

On trouve équivalent ou

Rejet de  $H_0$  si  $\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m_1)^2 + \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - m_0)^2 > k_\alpha$

$$\left( \frac{m_0^2 - m_1^2}{2\sigma^2} \right) + \sum_{i=1}^n x_i \left( \frac{m_1 - m_0}{\sigma^2} \right) > k_\alpha$$

$m_1 > m_0$

Tir équivalent

Rejet de  $H_0$  si  $\sum_{i=1}^n x_i > U_\alpha$

$T$

[TD du 3d11/2022]

Exo 1

1) La vraisemblance s'écrit  $L(t_1, \dots, t_n; \theta) = \prod_{i=1}^n f_T(t_i) = \theta^n e^{-\theta \sum_{i=1}^n t_i}$

L'estimation du maximum de vraisemblance est

$$\hat{\theta}_{\text{mr}} = \arg \max_{\theta} L(t_1, \dots, t_n; \theta) = \arg \max_{\theta} \ln L(t_1, \dots, t_n; \theta)$$

Comme d'habitude, il est plus simple de travailler avec la log vraisemblance qui est maximale pour  $\theta$  vérifiant

$$\frac{\partial \ln L}{\partial \theta} = 0 \Leftrightarrow \frac{\partial}{\partial \theta} \left[ n \ln \theta - \theta \sum_{i=1}^n t_i \right] = 0$$

$$\Leftrightarrow \frac{n}{\theta} - \sum_{i=1}^n t_i = 0$$

$$\Leftrightarrow \theta = \frac{n}{\sum_{i=1}^n t_i} \quad (1)$$

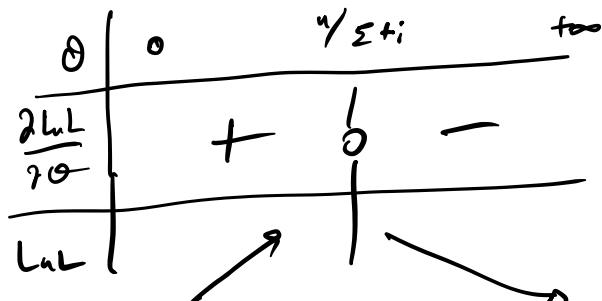
On en déduit

$$\hat{\theta}_{MV} = \frac{n}{\sum_{i=1}^n t_i}$$

Rq : si on demande de vérifier que (1) est bien le maximum de vraisemblance, on peut étudier le signe de  $\frac{\partial \ln L}{\partial \theta}$  et faire un tableau de variations :

$$\frac{\partial \ln L}{\partial \theta} \geq 0 \Leftrightarrow \frac{n}{\theta} - \sum_{i=1}^n t_i > 0 \Leftrightarrow \theta < \frac{n}{\sum t_i}$$

d'où



$\theta = \frac{n}{\sum t_i}$  est donc bien le maximum unique de la vraisemblance.

## 2) Estimateur MAP

$$\hat{\theta}_{MAP} = \arg \max_{\theta} p(\theta | t_1, \dots, t_n)$$

$$= \arg \max_{\theta} \frac{p(t_1, \dots, t_n | \theta) p(\theta)}{p(t_1, \dots, t_n)}$$

Comme  $p(t_1, \dots, t_n)$  est indépendante de  $\theta$ , on peut travailler avec  $p(t_1, \dots, t_n | \theta) p(\theta)$ .

$$\text{On a } p(t_1, \dots, t_n | \theta) p(\theta) = \theta^n e^{-\theta \sum t_i} \times \lambda e^{-\lambda \theta}$$

~~$\theta < t_i - \lambda$~~

$$\propto \theta^n e^{-\nu(\theta)} e^{-\theta \sum t_i}$$

La vraisemblance est  $p(t_1, \dots, t_n; \theta) = \theta^n e^{-\theta \sum t_i}$   
 donc pour passer de la vraisemblance à la loi a posteriori,  
 il suffit de remplacer  $\sum t_i$  par  $\sum t_i + \lambda$  d'où

$$\hat{\theta}_{MAP} = \frac{n}{\sum t_i + \lambda}$$

### Estimateur MMSE

$$\hat{\theta}_{MMSE} = E[\theta | t_1, \dots, t_n]$$

qui est la moyenne de la loi a posteriori - Donc, on va chercher la loi a posteriori et déterminer sa moyenne à l'aide des tables de loi.

Comme  $p(\theta | t_1, \dots, t_n) \propto \theta^n e^{-\theta(\sum t_i + \lambda)}$

on reconnaît une loi gamma  $G(n+1, \sum_{i=1}^n t_i + \lambda)$

dont la moyenne est (voir table)

$$\frac{n+1}{\sum t_i + \lambda}$$

On en déduit

$$\hat{\theta}_{MMSE} = \frac{n+1}{\sum_{i=1}^n t_i + \lambda}$$

Quand  $n$  est grand, on remarque que  $\hat{\theta}_{MAP}$  se comporte comme  $\hat{\theta}_{MMSE}$  - On oublie la loi a priori lorsqu'on a beaucoup d'observations !

$$\frac{\hat{\theta}_{MAP}}{\hat{\theta}_{ML}} = \frac{n}{\sum t_i + 1} \times \frac{\sum t_i}{n}$$

$$= \frac{1}{1 + \frac{1}{\sum t_i}} \xrightarrow[n \rightarrow \infty]{} 0$$

donc  $\frac{\hat{\theta}_{MAP}}{\hat{\theta}_{ML}} \xrightarrow[n \rightarrow \infty]{} 1$

Exo 2 1) la vraisemblance est

$$L(\beta_1, \beta_2; \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(\beta_1-\theta)^2}{2\sigma^2}} \times \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(\beta_2-\theta)^2}{2\sigma^2}}$$

$$= \frac{1}{2\pi\sigma^2} \exp \left\{ -\frac{1}{2\sigma^2} [(\beta_1-\theta)^2 + (\beta_2-\theta)^2] \right\}$$

Comme  $\theta \in [0, 1]$ , l'estimateur du max de vraisemblance de  $\theta$  vaut 0 si

$$L(\beta_1, \beta_2; \theta=0) \geq L(\beta_1, \beta_2; \theta=1)$$

On en déduit

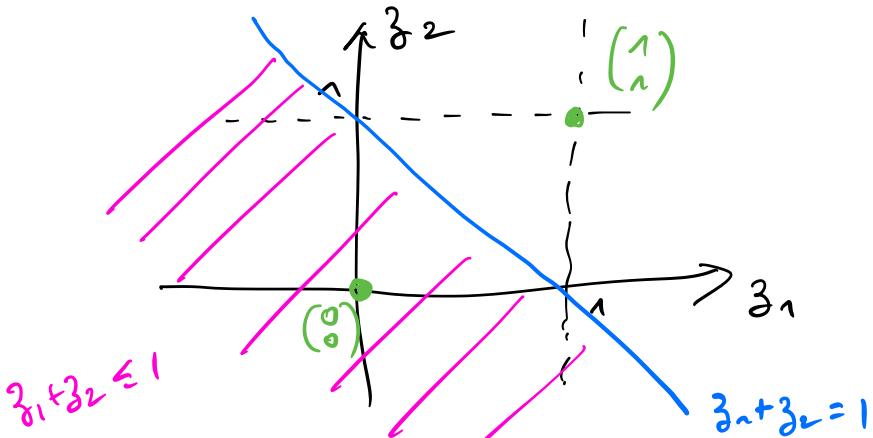
$$\hat{\theta}_{ML} = 0 \Leftrightarrow \frac{1}{2\pi\sigma^2} \exp \left[ -\frac{1}{2\sigma^2} (\beta_1^2 + \beta_2^2) \right] \geq \frac{1}{2\pi\sigma^2} \exp \left[ -\frac{1}{2\sigma^2} ((\beta_1-1)^2 + (\beta_2-1)^2) \right]$$

Surt

$$\hat{\theta}_{ML} = 0 \Leftrightarrow -\frac{1}{2\sigma^2} (\beta_1^2 + \beta_2^2) \geq -\frac{1}{2\sigma^2} (\beta_1^2 + \beta_2^2 - 2\beta_1 - 2\beta_2 + 2)$$

$$\Leftrightarrow 0 \geq \frac{\beta_1 + \beta_2 - 1}{\sigma^2}$$

$$\hat{\theta}_{\text{MV}} = 0 \Leftrightarrow \hat{\beta}_1 + \hat{\beta}_2 \leq 1$$



On choisit donc  $\hat{\theta}_{\text{MV}} = 0$  si le point  $(\hat{\beta}_1, \hat{\beta}_2)$  est plus proche de  $(0)$  que de  $(1)$ , ce qui est logique : quand il n'y a pas de bruit ( $e_1 = e_2 = 0$ ), on a

$$\left( \begin{pmatrix} \beta_1 \\ \beta_2 \end{pmatrix} = \begin{pmatrix} \theta \\ 0 \end{pmatrix} \right) = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \text{si } \theta = 0$$

$$= \begin{pmatrix} 1 \\ 1 \end{pmatrix} \quad \text{si } \theta = 1$$

## v) Estimateur MAP

$$\hat{\theta}_{\text{MAP}} = 0 \Leftrightarrow L(\beta_1, \beta_2; \theta=0) P[\theta=0] \geq L(\beta_1, \beta_2; \theta=1) P[\theta=1]$$

$$\Leftrightarrow P[\theta=0 | \beta_1, \beta_2] \propto P[\theta=1 | \beta_1, \beta_2]$$

↑  
proportionnel à

si  $P[\theta=0] = P[\theta=1] = \frac{1}{2}$ , on a

$$\hat{\theta}_{\text{MAP}} = \hat{\theta}_{\text{MV}}$$

Par contre si  $P[\theta=0] = p$  et  $P[\theta=1] = 1-p$ ,

$$\hat{\theta}_{MAP} = 0 \Leftrightarrow \frac{1}{2\pi\sigma^2} \exp\left[-\frac{1}{2\sigma^2}(z_1^2 + z_2^2)\right] p > \frac{1}{2\pi\sigma^2} \exp\left[-\frac{1}{2\sigma^2}(z_1^{-1})^2 + (z_2^{-1})^2\right] \times (1-p)$$

Simpl

$$\hat{\theta}_{MAP} = 0 \Leftrightarrow \ln p - \frac{1}{2\sigma^2}(z_1^2 + z_2^2) \geq \ln(1-p) - \frac{1}{2\sigma^2}(z_1^{-1})^2 + (z_2^{-1})^2$$

$$\Leftrightarrow \ln\left(\frac{p}{1-p}\right) \geq -\frac{1}{2\sigma^2}[-2z_1 - 2z_2 + 2] = \frac{z_1 + z_2 - 1}{\sigma^2}$$

d'où

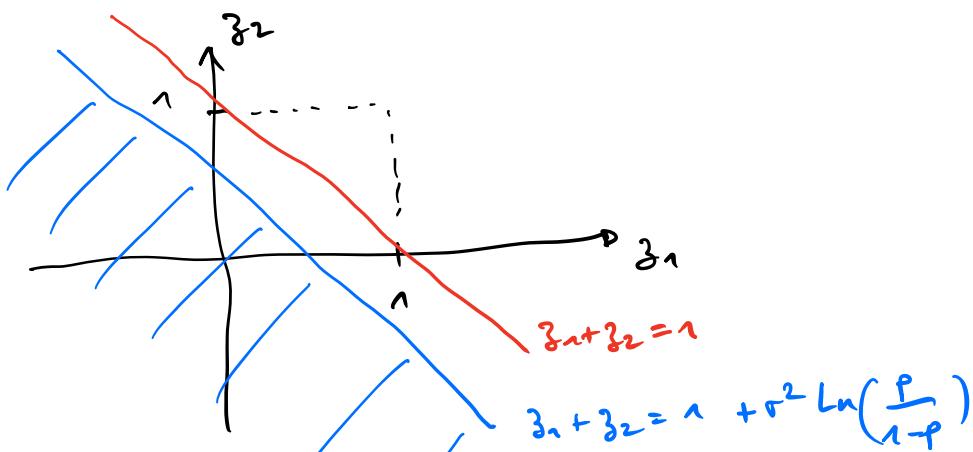
$$\hat{\theta}_{MAP} = 0 \Leftrightarrow z_1 + z_2 \leq 1 + \sigma^2 \ln\left(\frac{p}{1-p}\right)$$

- Si  $p < \frac{1}{2}$  (on a plus de chance d'avoir a priori  $\theta = 1$  que  $\theta = 0$ )

alors  $\frac{p}{1-p} < 1$  donc  $\ln\left(\frac{p}{1-p}\right) < 0$ , ce qui signifie

que  $1 + \sigma^2 \ln\left(\frac{p}{1-p}\right) < 1$ . La zone associée

à  $\hat{\theta}_{MAP} = 0$  est représentée ci-dessous

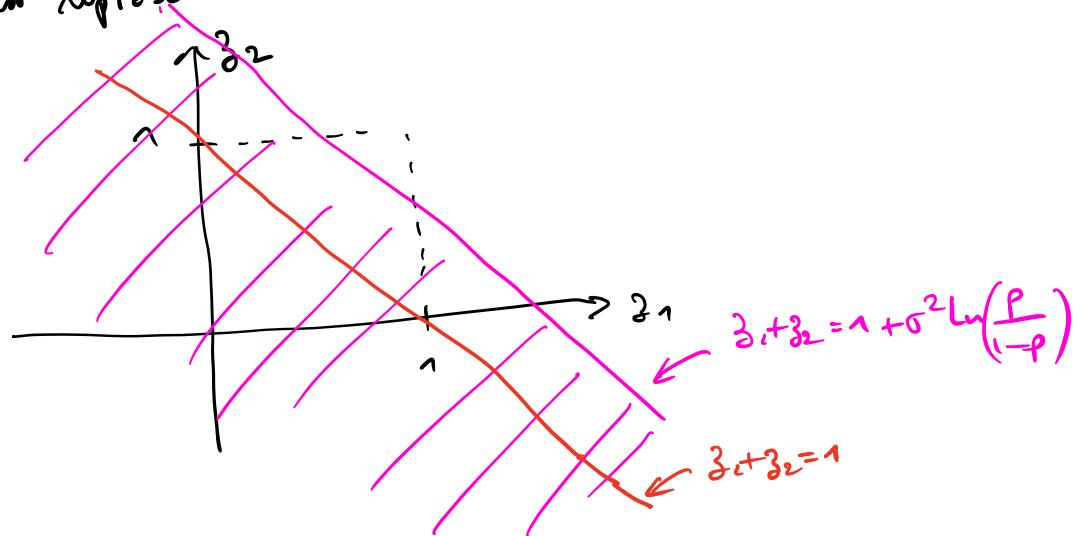


Comme  $p = P[\theta=0] < \frac{1}{2}$ , la zone associée à  $\hat{\theta}_{MAP} = 0$  est plus petite que celle délimitée par la droite  $z_1 + z_2 = 1$ .

- Si  $p > \frac{1}{2}$ , on a plus de chance a priori d'avoir  $\theta = 0$  que  $\theta = 1$

donc  $\frac{p}{1-p} > 1 \Rightarrow \ln\left(\frac{p}{1-p}\right) > 0$ , ce qui signifie

$1 + \sigma^2 \ln\left(\frac{p}{1-p}\right) > 1$ . La zone associée à  $\hat{\theta}_{MAP} = 0$  est représentée ci-dessous



Comme  $p = P(\theta=0) > \frac{1}{2}$ , la zone associée à  $\hat{\theta}_{MAP} = 0$  est plus grande que quand  $p = \frac{1}{2}$  (délimitée par la droite  $\zeta_1 + \zeta_2 = 1$ )

[TD du 6/12/2022]

$$\alpha = P[\text{Rejet de } H_0 \mid H_0 \text{ vraie}] \quad \text{PFA}$$

$$\beta = P[\text{Rejet de } H_1 \mid H_1 \text{ vraie}] \quad \text{PND}$$

NEYMAN PEARSON      à  $\alpha$  fixé

On rejette  $H_0$  si  $\frac{L(x_1, \dots, x_n; \mu_1)}{L(x_1, \dots, x_n; \mu_0)} > \text{Seuil} = S_\alpha$

⇒ Rejet de  $H_0$  si  $\frac{\prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma_i^2}} \exp\left(-\frac{x_i^2}{2\sigma_i^2}\right)}{\prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma_0^2}} \exp\left(-\frac{x_i^2}{2\sigma_0^2}\right)} > \text{Seuil}$

$$\frac{\frac{1}{(2\pi\sigma_1^2)^{n/2}} \exp\left(-\frac{1}{2\sigma_1^2} \sum_{i=1}^n x_i^2\right)}{\frac{1}{(2\pi\sigma_0^2)^{n/2}} \exp\left(-\frac{1}{2\sigma_0^2} \sum_{i=1}^n x_i^2\right)} > s_{\text{crit}} = s_1$$

Un test équivalent est

$$\text{Rejet de } H_0 \text{ si } -\frac{n}{2} \ln(2\pi\sigma_1^2) - \frac{1}{2\sigma_1^2} \sum_{i=1}^n x_i^2 - \frac{n}{2} \ln(2\pi\sigma_0^2) + \frac{1}{2\sigma_0^2} \sum_{i=1}^n x_i^2 > s_2$$

Un test équivalent sur

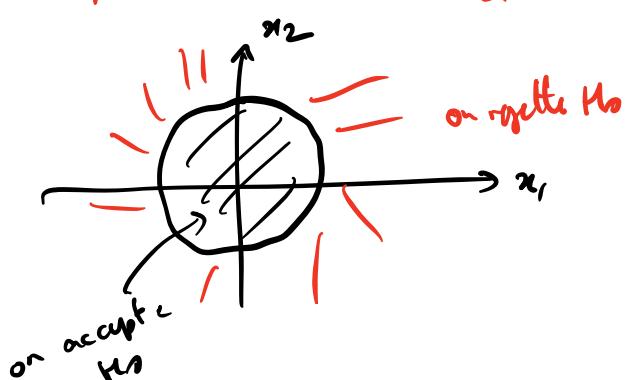
$$\text{Rejet de } H_0 \text{ si } \underbrace{\left(\frac{1}{\sigma_0^2} - \frac{1}{\sigma_1^2}\right) \sum_{i=1}^n x_i^2}_{c} > s_3$$

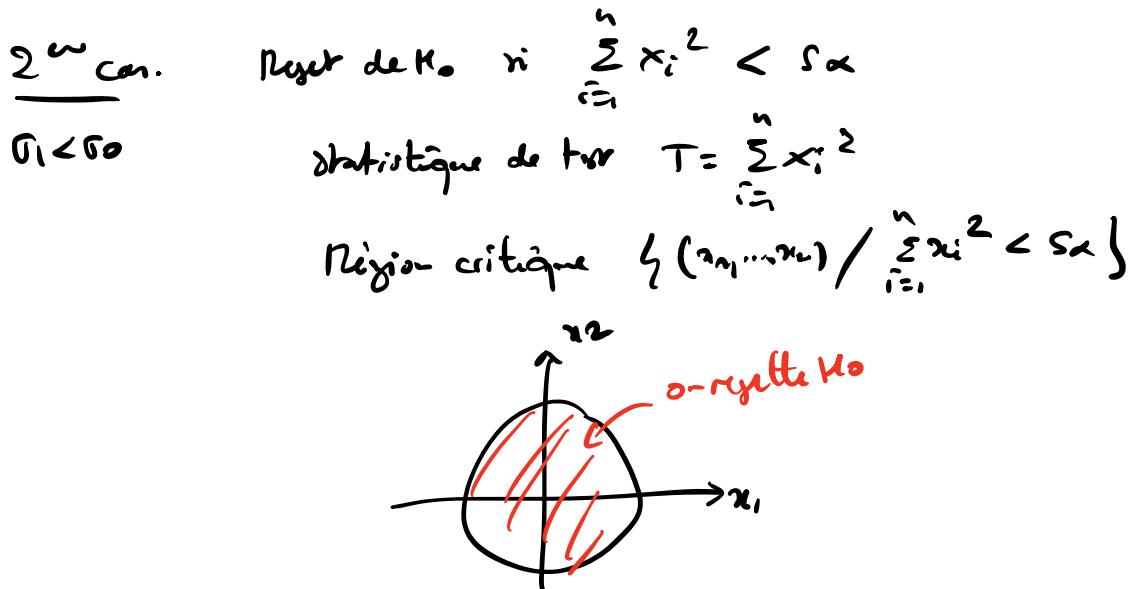
1<sup>er</sup> cas  $\boxed{\sigma_1 > \sigma_0}$   $\Leftrightarrow \frac{1}{\sigma_1^2} < \frac{1}{\sigma_0^2} \Leftrightarrow c > 0$

Rejet de  $H_0$  si  $\boxed{\sum_{i=1}^n x_i^2 > s_\alpha}$

Stat de test  $T = \sum_{i=1}^n x_i^2$

Réjection critique  $\{(x_1, \dots, x_n) / \sum_{i=1}^n x_i^2 > s_\alpha\}$





## 2) Calcul de $\beta$

Sensitif  $s_\alpha$

$$\alpha = P[\text{Rejet de } H_0 \mid H_0 \text{ vraie}]$$

$$= P\left[\sum x_i^2 > s_\alpha \mid \sigma^2 = \sigma_0^2\right]$$

$$X_i \sim N(0, \sigma^2) \text{ donc } \frac{X_i}{\sigma} \sim N(0, 1)$$

$$= P\left[\frac{\sum x_i^2}{\sigma_0^2} > \frac{s_\alpha}{\sigma_0^2} \mid \sigma^2 = \sigma_0^2\right]$$

v ~  $\chi_n^2$

$$\alpha = \Phi_n\left(\frac{s_\alpha}{\sigma_0^2}\right)$$

$$\Rightarrow \frac{s_\alpha}{\sigma_0^2} = \Phi_n^{-1}(\alpha) \Rightarrow s_\alpha = \sigma_0^2 \Phi_n^{-1}(\alpha)$$

$$\begin{aligned} \beta &= P[\text{Rejet de } H_1 \mid H_1 \text{ vraie}] \\ &= P\left[\sum x_i^2 < s_\alpha \mid \sigma^2 = \sigma_1^2\right] \\ &= P\left[\sum x_i^2 < s_\alpha \mid v \sim \chi_n^2\right] \end{aligned}$$

$$\underbrace{\frac{\sigma_0^2}{\sigma_i^2} - \frac{\sigma_1^2}{\sigma_i^2}}_{\nabla} \rightarrow$$

$$\beta = 1 - \phi_n \left( \frac{s\alpha}{\sigma_i^2} \right)$$

$$\pi = 1 - \beta = \phi_n \left( \frac{s\alpha}{\sigma_i^2} \right)$$

3) Courbes GR       $\pi = \text{fonction de } \alpha$

$$\pi = \phi_n \left( \frac{s\alpha}{\sigma_i^2} \right) = \boxed{\phi_n \left( \frac{\sigma_0^2}{\sigma_i^2} \phi_n^{-1}(\alpha) \right) = \pi}$$

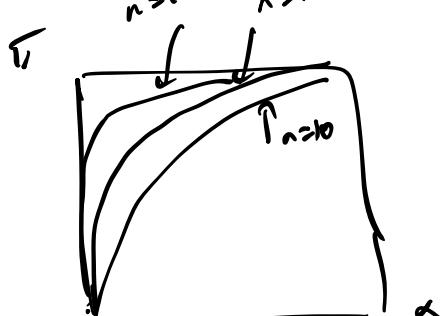
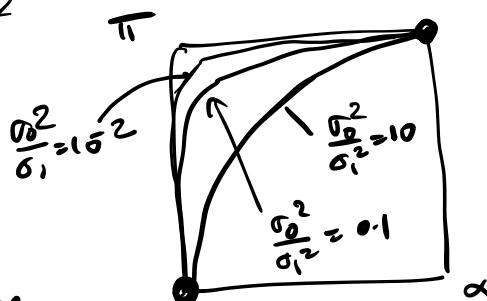
Courbes GR

Rq  $\phi_n(x) = \int_x^{+\infty} - dx$



$\phi_n$  est une fonction croissante

Donc si  $\frac{\sigma_0^2}{\sigma_i^2} \downarrow$  alors  $\phi_n \uparrow$



$$4) \quad T = \sum_{i=1}^n x_i^2 \quad E(T) = n E[x_i^2] \quad (=nm)$$

$$x_i \sim N(0, \sigma^2)$$

$$E(x_i^2) = \text{Var}(x_i) + E^2[x_i] = \sigma^2 + 0 = \sigma^2$$

m = \sigma^2

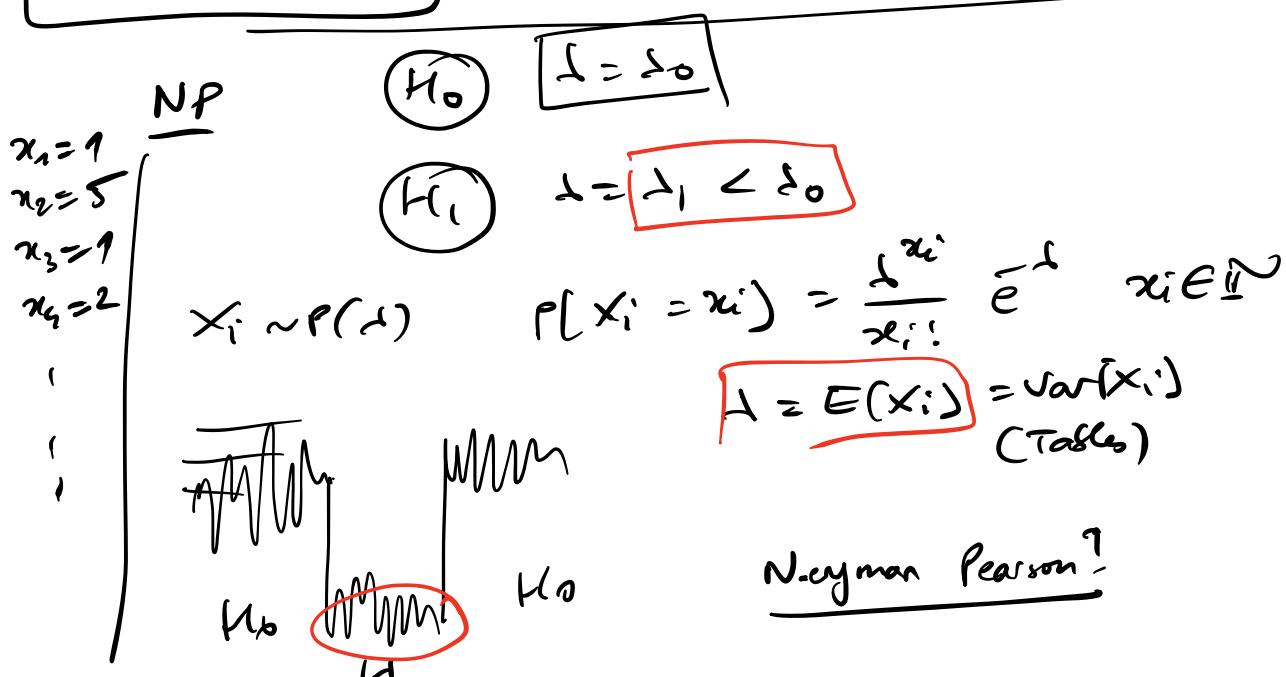
$$\text{Var}(T) = n \text{Var}(x_i^2)$$

$$\text{Var}(x_i^2) = \underbrace{E(x_i^4)}_{\sigma^4} - \overline{E(x_i^2)}^2 = \boxed{2\sigma^4}$$

$$\int x^4 p(x) dx = 3\sigma^4$$

$T \sim N(n\sigma^2, 2n\sigma^4)$

Cours du 21/12/2022



511

$\alpha$  fixé, le test qui minimise  $\beta$  est défini par

$$\text{Rejet de } H_0 \text{ si } \frac{L(x_1, \dots, x_n; \lambda_1)}{L(x_1, \dots, x_n; \lambda_0)} > \gamma_\alpha$$

$$s_i \quad \frac{P[X_1=x_1, \dots, X_n=x_n; \lambda=\lambda_1]}{P[\quad ; \lambda=\lambda_0]} > \gamma_\alpha$$

$$s_i \quad \frac{\prod_{i=1}^n \left[ \frac{x_i}{\lambda_1} e^{-\lambda_1} \right]}{\prod_{i=1}^n \left[ \frac{x_i}{\lambda_0} e^{-\lambda_0} \right]} > \gamma_\alpha$$

$$F_{\lambda_0} \quad \frac{\lambda_1 \sum_{i=1}^n x_i}{\lambda_0} \frac{e^{-n\lambda_1}}{e^{-n\lambda_0}} > \gamma_\alpha //$$

On rejette  $H_0$  si

$$\frac{\sum_{i=1}^n x_i}{T} \left( \ln \lambda_1 - \ln \lambda_0 \right) > k_\alpha$$

Donc

on rejette  $H_0$  si  $\sum_{i=1}^n x_i < A_\alpha$

stat de test  $T = \sum_{i=1}^n x_i$

- Zone critique  $\{(x_1, \dots, x_n) / \sum_{i=1}^n x_i < A\alpha\}$

$\alpha = 0.01$  Comment trouver  $A\alpha$ ?  $\beta$ ?

$$\alpha (= 0.01) = P[\text{Rejet Ho | Ho vraie}]$$

$$= P\left[ \underbrace{\sum_{i=1}^n x_i}_{T} < A\alpha \mid \lambda = \lambda_0 \right]$$

= Fonction de répartition de  $T = \sum_{i=1}^n x_i$   
au point  $A\alpha$   $= F_0(A\alpha)$

$h_T(x) = \sum_{i=1}^n x_i$

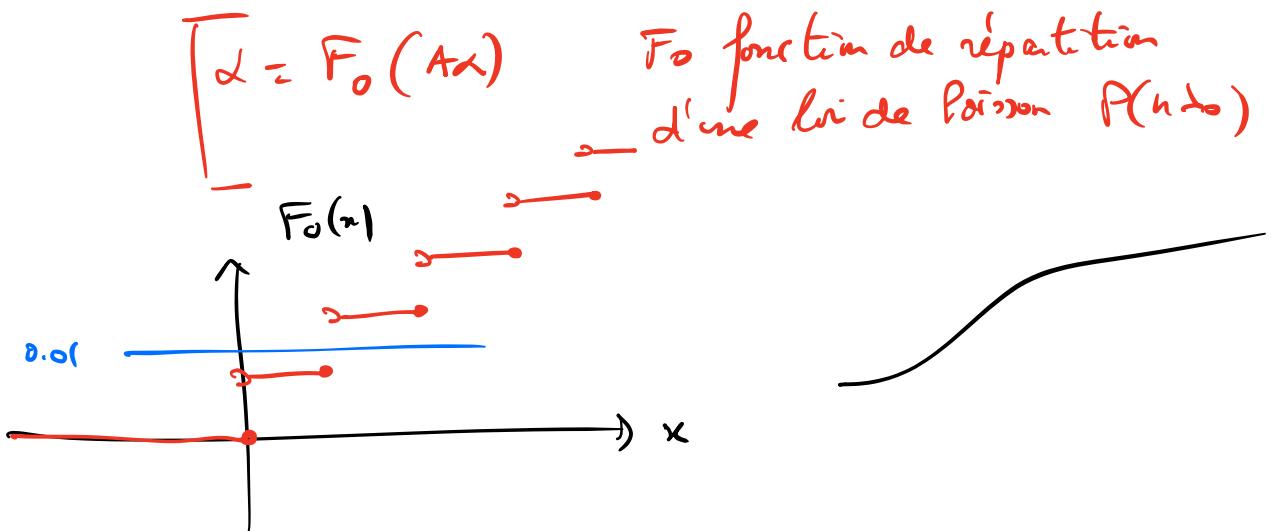
$$\begin{aligned} \phi_T(t) &= E[e^{itT}] \\ &= E\left[ e^{\frac{it}{n} \sum_{k=1}^n x_k} \right] = \prod_{k=1}^n \underbrace{E[e^{itx_k}]}_{\phi_{X_k}(t)} \end{aligned}$$

$$\begin{aligned} &\exp(it\phi_{X_k}(t)) \\ &= \exp(it\lambda(e^{it})) \end{aligned}$$

c'est la fonction caractéristique  
d'une loi de Poisson de paramètre  $n\lambda$

ire

$T = \sum_{i=1}^n x_i \sim P(n\lambda)$



$$F_0(A\lambda) = 0.01$$

La recherche de  $A\lambda$  n'est plus qu'pénible !!!

On approche la loi de  $T = \sum_{i=1}^n X_i$  par une loi normale  
en vertu du théorème central limite

$$1. \quad \sum_{i=1}^n X_i \underset{n \text{ grand}}{\approx} N(n\lambda, n\lambda)$$

$$E(\sum X_i) = \sum E(X_i) = n\lambda$$

$$\text{Var}(\sum X_i) = \sum \text{Var} X_i = n\lambda$$

$X_1, \dots, X_n$  ind

$$\begin{aligned}
 \alpha &= P(T < A\lambda) \quad (\text{d'abord}) \\
 &\approx P[X < A\lambda] \quad X \sim N(n\lambda, n\lambda)
 \end{aligned}$$

$$\approx P\left(\frac{x - n\mu_0}{\sqrt{n\sigma_0^2}} < \frac{A\alpha - n\mu_0}{\sqrt{n\sigma_0^2}}\right)$$

$$\approx F\left(\frac{A\alpha - n\mu_0}{\sqrt{n\sigma_0^2}}\right)$$

F fonction de  
répartition de la loi  
 $N(\mu_0)$

donc

$$A\alpha \approx F'(\alpha) \sqrt{n\sigma_0^2} + n\mu_0$$

TD du 7/12/2022

i) Rejet de  $H_0$  si  $\frac{L(x_1, \dots, x_n; H_1)}{L(x_1, \dots, x_n; H_0)} > s_\alpha$

si  $\frac{\prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma_1^2}} \exp\left(-\frac{x_i^2}{2\sigma_1^2}\right)}{\prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma_0^2}} \exp\left(-\frac{x_i^2}{2\sigma_0^2}\right)} > s_\alpha$

si  $\left(\frac{\sigma_0^2}{\sigma_1^2}\right)^{n/2} \exp\left(-\frac{1}{2\sigma_1^2} \sum_{i=1}^n x_i^2 + \frac{1}{2\sigma_0^2} \sum_{i=1}^n x_i^2\right) > s_\alpha$

Rejet de  $H_0$  si  $\sum_{i=1}^n x_i^2 \left(\frac{1}{2\sigma_0^2} - \frac{1}{2\sigma_1^2}\right) > k_\alpha$   
 $\underbrace{s_0?}_{>0?} \text{ ou } < 0?$

Si  $\sigma_1 > \sigma_0$  alors  $\frac{1}{\sigma_1^2} < \frac{1}{\sigma_0^2}$  donc  $\frac{1}{\sigma_0^2} - \frac{1}{\sigma_1^2} > 0$

done rejet de  $H_0$  si  $T = \sum_{i=1}^n x_i^2 > s_\alpha$

Si  $\sigma_1 < \sigma_0$

rejet de  $H_0$  si  $T = \sum_{i=1}^n x_i^2 < s_\alpha$

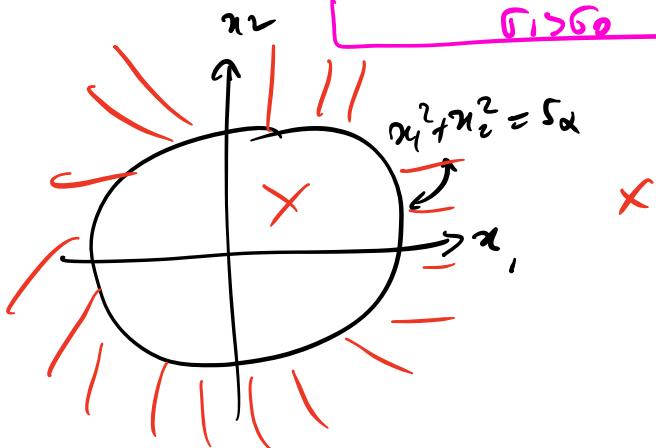
$\sigma_1 > \sigma_0$

$$\text{Var } X = E(X^2) - E(X)^2$$

Stat de  $H_0$   $T = \sum_{i=1}^n x_i^2$

Régiōn critique  $\{(x_1, \dots, x_n) / \sum_{i=1}^n x_i^2 > s_\alpha\}$

$\sigma_1 > \sigma_0$



2)  $\parallel s_\alpha ?$

$$\beta = P[\text{Rejet de } H_1 \mid H_1 \text{ vraie}]$$

Accepter  $H_1$

$$\alpha = P[\text{Rejet de } H_0 \mid H_0 \text{ vraie}]$$

$$= P\left[\sum_{i=1}^n x_i^2 > s_\alpha \mid \sigma^2 = \sigma_0^2\right]$$

$T$  l'indép sous  $H_0$

Rappel : Si  $Z_1, \dots, Z_n \sim N(0, 1)$  alors  $\sum_{i=1}^n Z_i^2 \sim \chi_n^2$

"  $z_1, \dots, z_n$  indépendants" //

$$x_i \sim N(\mu, \sigma^2) \Rightarrow \frac{x_i - \mu}{\sigma} \sim N(0, 1)$$

$$\boxed{\sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma}\right)^2 \sim \chi_n^2}$$

$$\alpha = P\left[\frac{\sum_{i=1}^n x_i^2}{\sigma^2} > \frac{s_\alpha}{\sigma^2} \mid \sigma^2 = \sigma_0^2\right]$$

$$\boxed{\alpha = 1 - F_{\chi_n^2}\left[\frac{s_\alpha}{\sigma_0^2}\right] \Rightarrow 1 - \alpha = F_{\chi_n^2}\left[\frac{s_\alpha}{\sigma_0^2}\right]}$$

$$\bar{F}'(1-\alpha) = \frac{s_\alpha}{\sigma_0^2}$$

$$\boxed{s_\alpha = \sigma_0^2 \bar{F}_{\chi_n^2}^{-1}(1-\alpha)} = \boxed{\sigma_0^2 \bar{F}'(1-\alpha)}$$

Calcul de  $\beta$

$$\beta = P[\text{Rejet H}_1 \mid H_1 \text{ vraie}]$$

$$= P\left[\sum_{i=1}^n x_i^2 \leq s_\alpha \mid \sigma^2 = \sigma_1^2\right]$$

$$= P\left[\frac{\sum_{i=1}^n x_i^2}{\sigma^2} \leq \frac{s_\alpha}{\sigma^2} \mid \sigma^2 = \sigma_1^2\right]$$

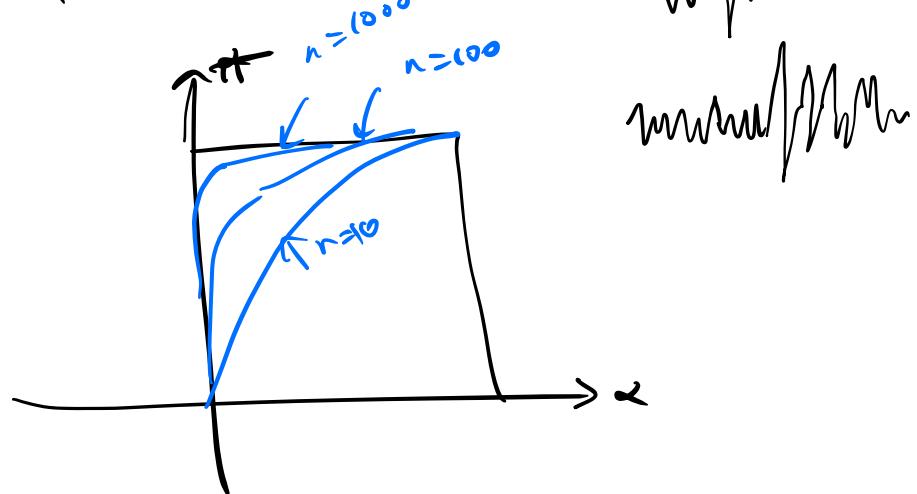
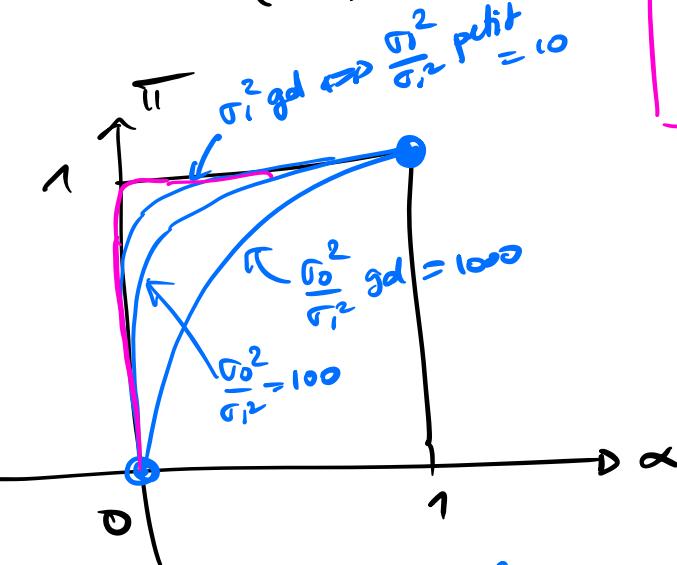
$$\boxed{\beta = F_{\chi_n^2}\left(\frac{s_\alpha}{\sigma_1^2}\right)} \quad (\star)$$

3) COURBES COR ( $\Pi = 1 - \beta$  en fonction de  $\alpha$ )

$$\begin{cases} \Pi = 1 - \beta = 1 - F_{X_n}^2\left(\frac{s_d}{\sigma_i^2}\right) \\ s_d = \sigma_0^2 F_{X_n}^{-1}(1-\alpha) \end{cases}$$

$$\Pi = 1 - F_{X_n}^2\left(\frac{\sigma_0^2}{\sigma_i^2} F^{-1}(1-\alpha)\right)$$

$$= \phi_n\left(\frac{\sigma_0^2}{\sigma_i^2} \phi_n^{-1}(\alpha)\right)$$



$$4) T = \sum_{i=1}^n x_i^2$$

[loi asymptotique de T]

→ quand n est grand  $T \sim N(?, ?)$

$$E(T) = E\left(\sum_{i=1}^n x_i^2\right) = \sum_{i=1}^n E\left(\frac{x_i^2}{\sigma_i^2}\right) \sigma_i^2$$

$$= n\sigma^2$$

$$\begin{aligned} \text{Var}(T) &= \text{Var}\left(\sum_{i=1}^n x_i^2\right) \\ &\stackrel{x_i \text{ i.i.d.}}{\rightarrow} = \sum_{i=1}^n \text{Var}(x_i^2) \\ &= n \text{Var}(x_1^2) = \boxed{n\sigma^2} \end{aligned}$$

$$\text{Var}(x_1^2) = E[x_1^4] - \frac{E[x_1^2]^2}{\sigma^4}$$

$$\int u^4 \frac{1}{\sqrt{2\pi\sigma^4}} \exp\left(-\frac{u^2}{2\sigma^2}\right) du = \frac{3\sigma^4}{\Gamma} \quad \text{par partie}$$

$$\text{Var } x_1^2 = 3\sigma^4 = \sigma^4 = \boxed{2\sigma^4}$$

donc  $T \sim N(n\sigma^2, 2n\sigma^4)$

$$\alpha = P(T > s_\alpha \mid \sigma^2 = \sigma_0^2)$$

$$= P\left(\frac{T - n\sigma^2}{\sqrt{2n\sigma^4}} > \frac{s_\alpha - n\sigma^2}{\sqrt{2n\sigma^4}} \mid U \sim N(0, 1)\right)$$

$$\alpha = 1 - F\left(\frac{s_\alpha - n\sigma_0^2}{\sqrt{2n\sigma_0^4}}\right)$$